


# LTR: Pointwise, Pairwise, Listwise

对于一个query  $q$ 和document  $d$ ，我们需要用神经信息检索的方法来计算 $q$ 和 $d$ 的相似程度

$$f(q, d)$$



但是对于基于排序的评价指标(MAP,NDCG,MRR)通常是不可微的，不能直接优化。所以需要一些可微的损失函数来优化Learning-to-Rank神经网络。

这对于LTR一般说来有三类方法：Pointwise, Pairwise和Listwise。

## 1.Pointwise

这个非常简单，和从前见到的分类/回归问题别无二致。预测模型给出的相似度为  $f(q, d)$ ，"真实"的相似度可以由用户是否点击这样的implicit feedback来打标签。损失函数可以是类似MSE这样的回归损失函数

$loss = ||y - f(q, d)||^2$ ，也可以是分类问题的交叉熵损失函数。

## 2.Pairwise: Predict pairwise preference between documents for a query.

$Loss = \max\{0, m + f(q, d_-) - f(q, d_+)\}$  如果负样本计算出来的相关性 +  $m >$  正样本计算出的相关性，那么 $loss > 0$ ，意味着模型把非正确的回答排在正确答案的上面；如果 $L$ 等于0，模型把正确的回答排在非正确的回答之上。总之该hinge损失函数的目的就是促使正确答案的得分比错误答案的得分高至少 $m$ 。和pointwise类似，在预测阶段按照得分排序。

在训练阶段，需要有query和正负样本对，所以Pairwise方法涉及到【负样本采样】，这个有很多文章研究过，之后会详细说明。

## 3.Listwise方法

复杂度过高，现实中几乎不会使用。