

# 美团: 深度位置交叉网络

之前去除position bias的方法：主要就是把位置作为神经网络中的特征/模块，放于网络的Wide部分，在线下训练时使用真实位置；但是，由于在预估过程中并不知道真实位置信息，所以在线上预估时使用固定位置。这种方法由于其简单性和有效性，在工业界被广泛应用，但是这种方法受“我们究竟使用哪个固定位置做测试”影响很大，所以又提出了position作为模块的方法，这样我们在线上就可以直接扔掉建模position bias的模块。例如，为了在线上预估时无需使用位置信息，PAL将样本的CTR建模为ProbSeen乘以pCTR，其中ProbSeen仅使用位置特征建模，而pCTR使用除了position之外的其他信息建模，在线上只使用pCTR模块作为CTR预估值。

但是，这种方法有两个缺点：

1. 训练和预估之间位置信息的不同处理方法，导致**线下线上间的不一致**问题。
2. "用户是否查看item只和item的位置有关"(PAL中的假设)--这个假设对问题过于简化了。事实是，**不同的用户通常具有不同的浏览习惯**：有些用户可能倾向于浏览更多item，而有些用户通常能快速做出决定；而且同一个用户在不同的**上下文搜索意图**中也会有不同的位置偏好，例如商场等地点词的搜索往往意图不明确导致高低位置的CTR差异并不大。故而，**位置偏差与用户、上下文都有关**，甚至可能与广告本身也有关，建模它们间的关系能更好地解决位置偏差问题。

- $eCPM = CTR * bid$

## 1. 深度位置交叉网络 (Deep Position-wise Interaction Network)

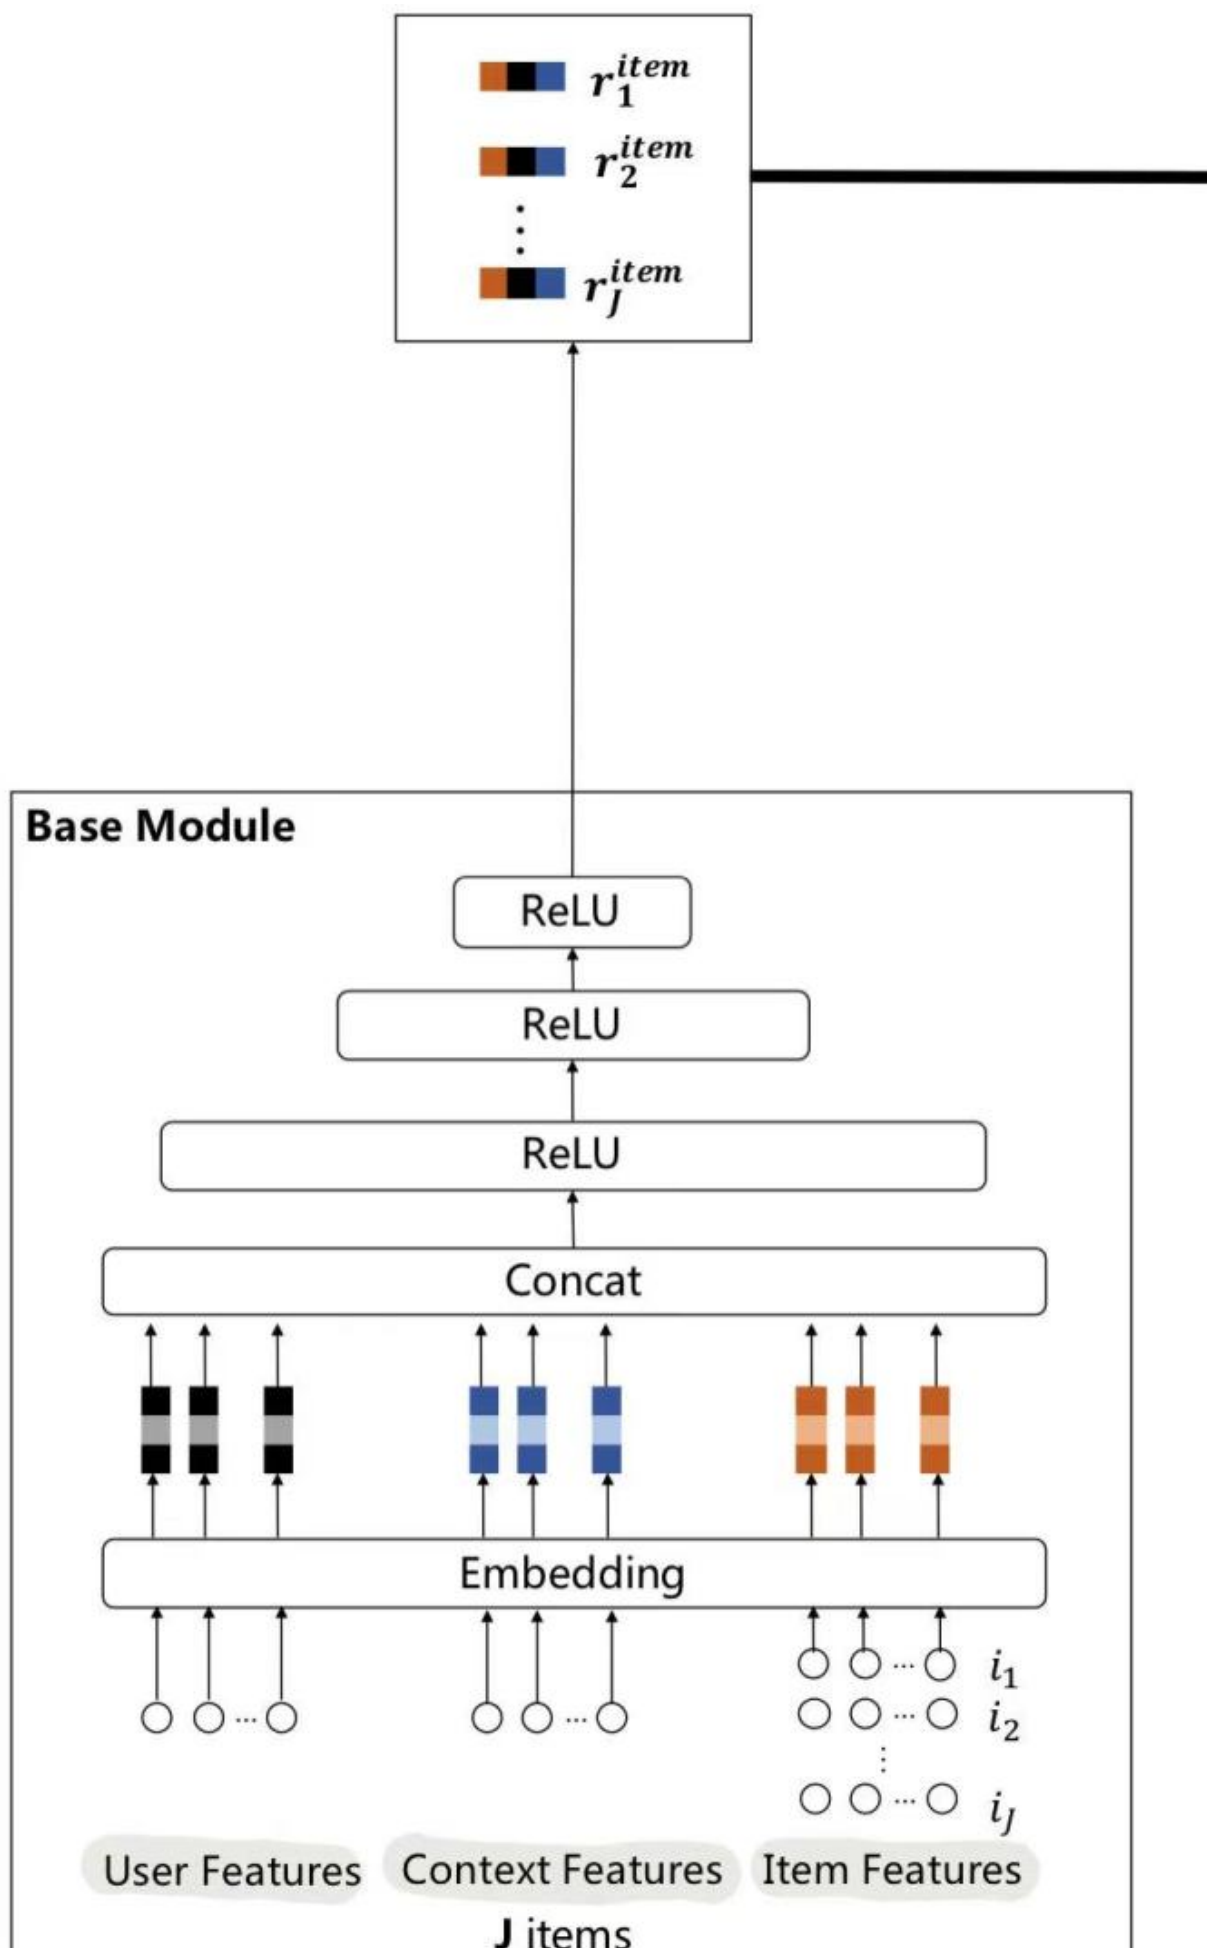
DPIN模型由三个模块组成：

- 处理  $J$  个**候选广告**的基础模块 (Base Module)，用来得到  $J$  个候选广告融合当前user feature、context feature的表征。
- 处理  $K$  个**候选位置**的深度位置交叉模块 (Deep Position-wise Interaction Module)
- 组合  $J$  个**广告**和  $K$  个**位置**的位置组合模块 (Position-wise Combination Module)

不同模块需预估的样本数量不一样，复杂模块预估的样本数量少（如深度位置交叉模块，只需预估  $K$  个位置），简单模块预估的样本数量多（如基础模块，需要预估全部的候选item）。通过这三个模块的组合，DPIN模型可以预估**每个广告在每个位置上的CTR**： $CTR_k^j$  是第  $j$  个广告在第  $k$  个位置的CTR预估值，广告的最终序可以通过最大化  $\sum CTR_k^j bid^j$  来确定，其中  $bid^j$  为广告的出价。之后，我们就可以用贪心的方法对这些广告进行排序了。

### 1.1 基础模块(Base Module)

得到所有  $J$  个广告的embedding，这个embedding是**融合了当前user feature和context feature**的表示。使用简单的Embedding+MLP结构：



$$\begin{aligned}
 u &= \text{Concat}(E(u_1), \dots, E(u_m)), & (2) & \text{user } B_m \text{ feature} \\
 c &= \text{Concat}(E(c_1), \dots, E(c_n)), & (3) & \text{context } B_n \text{ feature} \\
 i_j &= \text{Concat}(E(i_1^j), \dots, E(i_o^j)), & (4) & \text{第 } j \text{ 个 item } B_o \text{ feature} \\
 r_j^{\text{item}} &= \text{MLP}(\text{Concat}(u, c, i_j)), & (5) &
 \end{aligned}$$

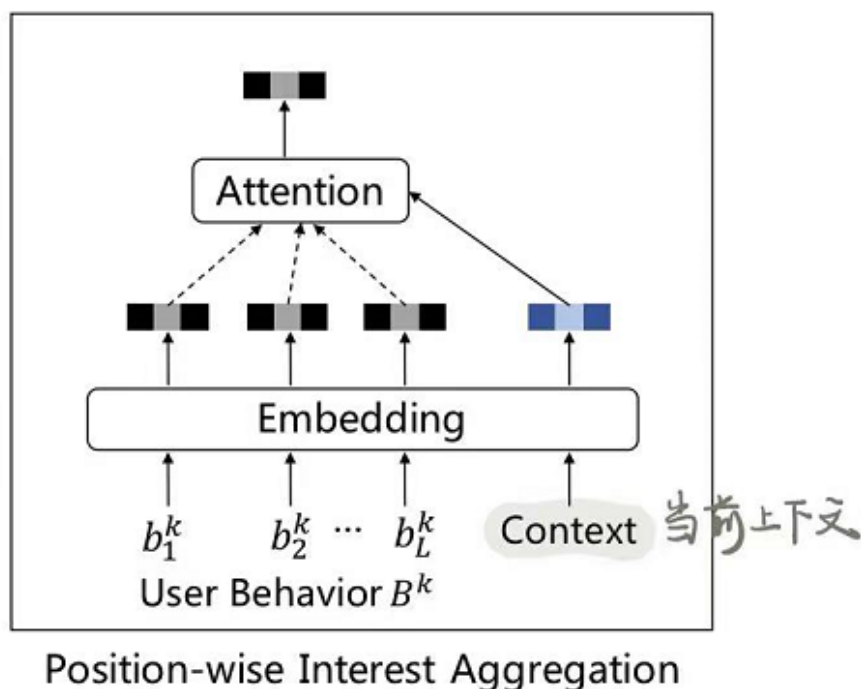
$u_1, \dots, u_m, c_1, \dots, c_n, i_1^j, \dots, i_o^j$  分别是当前用户特征集合、当前上下文特征集合以及第  $j$  个广告的特征集合。最终得到所有  $J$  个广告在当前用户、当前上下文中的embedding表示。

## 1.2 深度位置交叉模块 (Deep Position-wise Interaction Module)

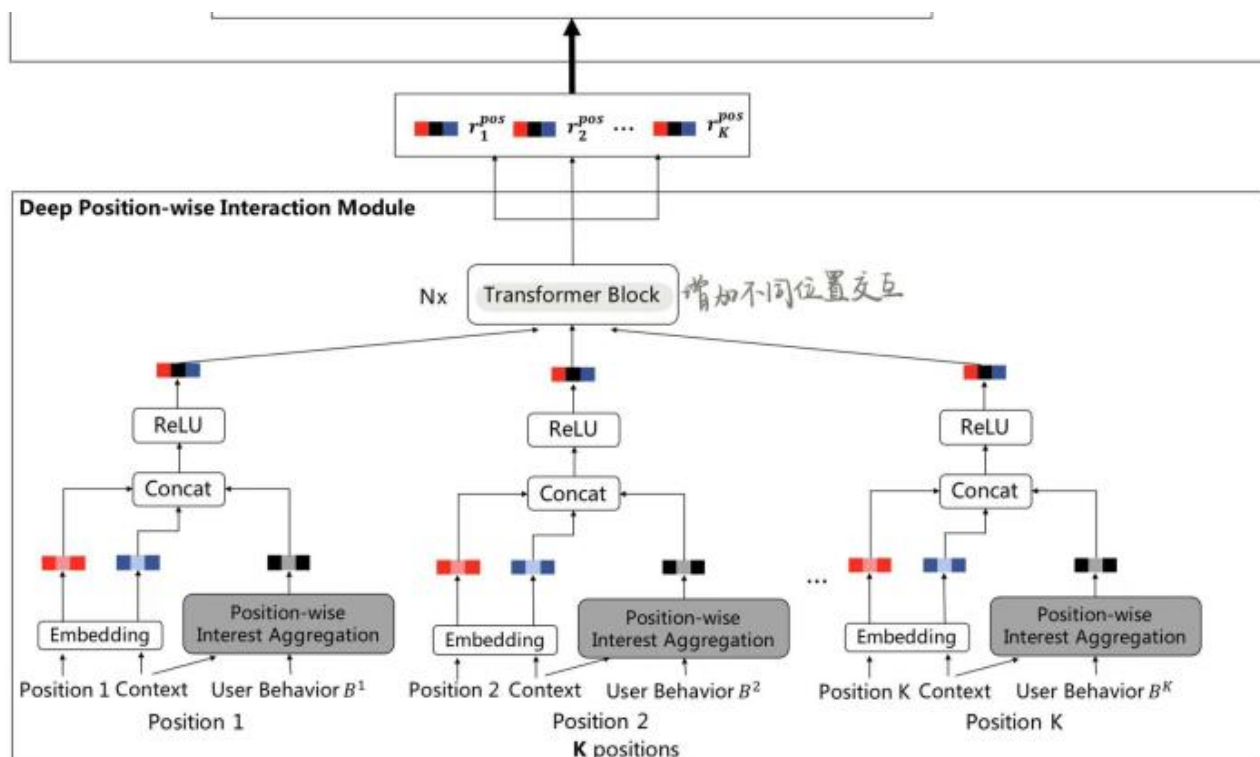
在上面这一步，我们已经完成了所有广告与user特征和context特征的交叉；我们还需要完成所有的  $J$  个广告与所有  $K$  个位置的交叉。如果直接把位置特征放在Base Module中，就要完成  $J * K$  次计算。而在大多数业务场景中，Base Module通常已经被高度优化，包含了大量特征甚至用户序列等信息，所以这样做复杂度太高了。因此，直接在base module中加入位置特征，并对所有广告在所有位置上做CTR预估是不可接受的。

因此，我们需要一个深度位置交叉模块，来专门建模不同位置信息。

为了得到不同位置在当前context、当前user下的embedding，使用了context特征和用户在第  $k$  个位置的历史行为序列：  $B_k = b_1^k, b_2^k, \dots, b_L^k$ ，其中  $b_l^k = [v_l^k, c_l^k]$  为用户在第  $k$  个位置上的历史第  $l$  个行为记录， $v_l$  为点击的item特征， $c_l^k$  为发生该行为时的context特征（包括搜索关键词、请求地理位置、一周中的第几天、一天中的第几个小时等）。这些行为序列和当前上下文 context 去计算注意力权重，对于与上下文越相关的行为可以给予越多的权重。



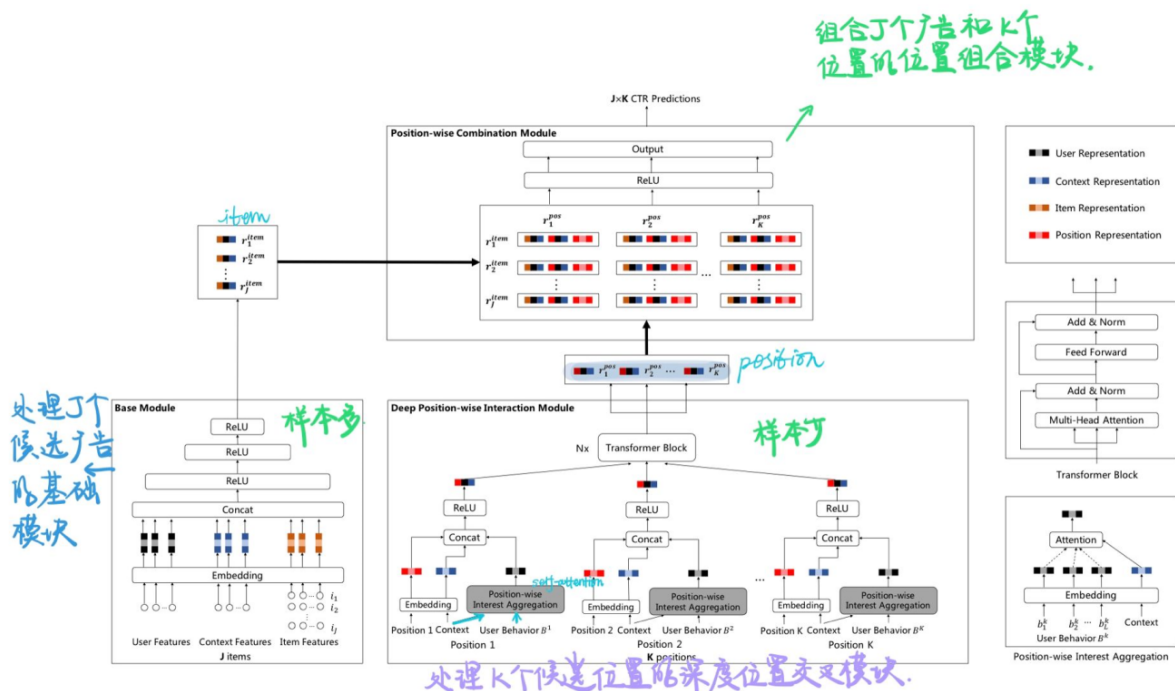
为了获得用户在其他位置上的行为序列信息，采用Transformer去学习不同位置兴趣的交互，最后得到K个输出，其中第  $k$  个位置被表示为  $r_k^{pos}$ 。



### 1.3 位置组合模块 (Position-wise Combination Module)

位置组合模块的目的是去组合  $J$  个广告和  $K$  个位置来预估每个广告在每个位置上的CTR. 把Base Module输出的  $J$  个广告embedding (包含了user, context特征交叉) 和深度位置交叉模块输出的  $K$  个位置embedding(包含user, context特征交叉)输出到一个MLP中, 得到  $J * K$  大小的预估矩阵。

整个模型可以使用真实位置通过批量梯度下降法进行训练，采用交叉熵作为损失函数。



## 2. 实验

- DIN: 没有做position bias的消除
- DIN+PosInWide: 在网络的Wide部分加入位置特征进行训练，在测试时位置特征取默认值。
- DIN+PAL: 采用PAL框架去建模位置信息。
- DIN+ActualPosInWide: 在网络的Wide部分加入位置特征进行训练，在测试时采用真实位置特征。
- DIN+Combination: 这个方法在DIN的基础上添加了位置组合模块，测试时采用真实位置特征。
- DPIN-Transformer: 在DPIN模型上去除了Transformer结构，来验证Transformer的作用。
- DPIN: DPIN模型。
- DPIN+ItemAction: 在DPIN的Base Module MLP层前添加深度位置交叉模块，并在位置兴趣聚合和位置非线性交叉中引入候选广告的信息，这个实验是DPIN方法模型性能的理论上限(因为在Base Module和深度位置交叉模块都做了候选item和position的交互)，然而服务性能是不可接受的。

MODEL	<i>Regular</i>		<i>Randomized</i>	
	AUC	PAUC	AUC	PAUC
DIN	0.7818	0.7090	0.7836	0.7223
DIN+PosInWide	0.7696	0.7109	0.7725	0.7239
DIN+PAL	0.7735	0.7128	0.7763	0.7254
DIN+ACUTALPosInWide	0.7928	0.7109	0.7938	0.7239
DIN+COMBINATION	0.7970	0.7172	0.7985	0.7294
DPIN-TRANSFORMER	0.7961	0.7148	0.7984	0.7283
<b>DPIN</b>	<b>0.7994</b>	<b>0.7216</b>	<b>0.8015</b>	<b>0.7350</b>
DPIN+ITEMACTION	0.7999	0.7223	0.8019	0.7356

A/B测试表明，DPIN在CTR上提高了2.25%，在RPM（每千次展示收入）上提高了2.15%。

参考：

[Yuki: SIGIR 2021 - 广告系统位置偏差的CTR模型优化方案 \[美团\] - Deep Position-wise Interaction Network](#)